UTS

PEMBELAJARAN MESIN



NAMA : Jonathan Juan Setyanto

NIM : 202431029

KELAS : E

DOSEN : Rizqia Cahyaningtyas, S.T., M.Kom.

NO.PC : 3

ASISTEN : 1. Muhammad Caesar Gemilang Pratama

2. Benedict Samuel Ardy

3.

4.

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2026/2027

DAFTAR ISI

Table of Contents

DAFTAR ISI 2
BAB I 3
PENDAHULUAN 3
1.1 Rumusan Masalah 3
1.2 Tujuan Masalah 3
1.3 Manfaat Masalah 3
BAB II 4
LANDASAN TEORI 4
BAB III 7
HASIL 7
BAB IV 29
PENUTUP 29
DAFTAR PUSTAKA 30

BAB I
PENDAHULUAN

1.1 Rumusan Masalah

1. Bagaimana karakteristik dan pola distribusi dataset yang diperoleh melalui tahapan Exploratory Data Analysis (EDA) serta preprocessing data?
2. Bagaimana penerapan dan hasil tingkat akurasi dari pelatihan model klasifikasi menggunakan algoritma Naive Bayes dan Decision Tree?
3. Bagaimana perbandingan performa serta efektivitas antara algoritma Naive Bayes dan Decision Tree berdasarkan hasil evaluasi akurasi data?

1.2 Tujuan Masalah

1. Mengidentifikasi karakteristik dataset serta mengimplementasikan teknik Exploratory Data Analysis (EDA) dan preprocessing data secara optimal.
2. Melatih dataset menggunakan algoritma Naive Bayes dan Decision Tree untuk menghitung nilai akurasi yang dihasilkan.
3. Menganalisis dan membandingkan kinerja akurasi dari kedua algoritma untuk menentukan model klasifikasi terbaik.

1.3 Manfaat Masalah

1. Memperdalam pemahaman konsep mengenai alur kerja machine learning, khususnya perbedaan karakteristik antara pendekatan probabilistik (Naive Bayes) dan berbasis struktur keputusan (Decision Tree).
2. Memberikan pengalaman langsung dalam mengolah data mentah melalui EDA dan preprocessing hingga siap dilatih oleh algoritma pembelajar.
3. Menghasilkan acuan komparatif yang jelas mengenai pemilihan algoritma klasifikasi yang paling sesuai berdasarkan akurasi dan karakteristik dataset yang diuji.

BAB II
LANDASAN TEORI

2.1 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) merupakan tahap analisis awal yang dilakukan untuk mengenali dan memahami karakteristik suatu dataset sebelum diterapkan ke dalam proses pemodelan. EDA dilakukan dengan menggunakan statistik deskriptif dan visualisasi data untuk mengetahui pola, hubungan antarvariabel, kecenderungan data, serta mendeteksi adanya anomali atau nilai pencilan (outlier).

Menurut (Husni et al., 2022), terdapat beberapa tahapan umum yang dilakukan dalam proses EDA, yaitu :

1. Memperoleh informasi dari dataset
   Menggali berbagai informasi dan pola yang terdapat dalam kumpulan data agar karakteristiknya dapat dipahami dengan lebih baik.
2. Menganalisis struktur dan variabel data
   Memeriksa struktur dataset, seperti tipe data, jumlah atribut, serta hubungan atau korelasi antarvariabel.
3. Mengidentifikasi anomali dan outlier
   Menemukan nilai yang tidak normal atau berbeda secara signifikan dari sebagian besar data karena dapat memengaruhi hasil pemodelan.
4. Melakukan visualisasi data
   Menyajikan informasi dalam bentuk grafik, seperti bar plot, scatter plot, dan heatmap, sehingga distribusi serta hubungan antarvariabel lebih mudah dianalisis.

2.2 Preprocessing Data

Data Preprocessing merupakan proses pengolahan data awal yang dilakukan untuk memperbaiki kualitas dataset sebelum digunakan dalam algoritma machine learning. Tahapan ini bertujuan untuk membersihkan dan menyesuaikan data mentah agar lebih terstruktur serta dapat diproses dengan baik oleh algoritma. Hal ini diperlukan karena dataset sering kali masih memiliki permasalahan, seperti nilai kosong (missing value), data ganda, maupun noise yang berpotensi memengaruhi hasil pembelajaran model.

Secara umum, proses preprocessing data terdiri dari beberapa tahapan berikut :

1. Pembersihan Data (Data Cleaning)
   Proses menangani permasalahan pada dataset, seperti menghapus data yang memiliki nilai kosong (missing value), mengganti nilai yang hilang melalui teknik imputasi menggunakan rata-rata atau median, serta menghilangkan data yang terduplikasi.
2. Seleksi Fitur (Feature Selection)

Tahapan pemilihan atribut yang dianggap memiliki hubungan atau kontribusi terhadap tujuan klasifikasi. Fitur yang tidak relevan atau memiliki informasi berulang dapat dihilangkan agar proses pemodelan lebih efektif.

3. Transformasi dan Normalisasi Data
   Proses menyesuaikan format serta skala data agar dapat digunakan oleh algoritma pembelajaran. Normalisasi dapat dilakukan menggunakan metode StandardScaler atau Min-Max Scaling. Selain itu, atribut kategorikal perlu dikonversi ke dalam bentuk numerik melalui teknik encoding.

2.3 Algoritma Naive Bayes

Naive Bayes Classifier (NBC) merupakan algoritma klasifikasi yang menggunakan pendekatan probabilitas berdasarkan Teorema Bayes. Algoritma ini digunakan untuk memperkirakan kemungkinan suatu data termasuk ke dalam kelas tertentu berdasarkan karakteristik atau atribut yang dimilikinya.

Naive Bayes memiliki asumsi dasar bahwa setiap atribut bersifat independen atau tidak saling bergantung dalam proses penentuan kelas. Meskipun asumsi tersebut cukup sederhana, algoritma ini tetap banyak digunakan dalam permasalahan klasifikasi karena proses perhitungannya relatif cepat.

Adapun persamaan dasar Teorema Bayes dapat dituliskan sebagai berikut :

$$P(H|X) = \frac{P(X|H)\ .\ P(H)}{P(X)}$$

Salah satu kelebihan algoritma Naive Bayes adalah mekanisme perhitungannya yang sederhana sehingga mampu memproses data dengan relatif cepat. Selain itu, algoritma ini juga dapat memberikan hasil klasifikasi yang baik meskipun menggunakan jumlah data pelatihan yang tidak terlalu besar.

2.4 Algoritma Decision Tree

Decision Tree atau pohon keputusan merupakan salah satu algoritma supervised learning yang digunakan untuk melakukan klasifikasi maupun prediksi berdasarkan serangkaian aturan keputusan. Algoritma ini memiliki struktur menyerupai pohon yang terdiri dari beberapa simpul (node) dan cabang untuk menggambarkan proses pengambilan keputusan berdasarkan atribut dalam dataset.

Struktur utama pada algoritma Decision Tree terdiri dari tiga bagian, yaitu :

1. Root Node (Simpul Akar)
   Merupakan bagian paling atas dari pohon keputusan yang menjadi titik awal proses klasifikasi. Simpul ini biasanya menggunakan atribut yang memiliki kemampuan terbaik dalam memisahkan data.
2. Decision Node (Simpul Keputusan)
   Merupakan simpul yang berada pada bagian percabangan dan digunakan untuk melakukan pengujian terhadap atribut tertentu berdasarkan kondisi yang telah ditentukan.
3. Leaf Node (Simpul Daun)

Merupakan bagian akhir dari pohon keputusan yang menunjukkan hasil klasifikasi atau prediksi berupa label kelas.

Dalam proses pembentukan pohon keputusan, algoritma seperti ID3 dan C4.5 menggunakan perhitungan Entropy dan Information Gain untuk menentukan atribut yang paling tepat sebagai pemisah data (split attribute).

Rumus perhitungan Entropy adalah sebagai berikut :

$$Entropy(S) = -\sum_{i=1}^{n} p_i \, log_2(p_i)$$

Sementara itu, perhitungan *Information Gain* dapat dirumuskan sebagai berikut :

$$Gain(S, A) = Entropy(S) - \sum_{i=1}^{n} \frac{|S_i|}{|S|} \, . Entropy(S_i)$$

Melalui perhitungan tersebut, atribut dengan nilai Information Gain tertinggi dipilih sebagai atribut pemisah karena dianggap mampu memberikan pengurangan ketidakpastian terbesar dalam proses klasifikasi.

BAB III
HASIL

Pada UTS praktikum ini, saya mendapat dataset “heart disease” dan algoritma Naive Bayes – Decision Tree.

3.1 Exploratory Data Analysis (EDA)

1. Import Library

Import Library

```
[1]: import pandas as pd
     import numpy as np
     import matplotlib.pyplot as plt
     import seaborn as sns

     # Agar grafik lebih rapi
     sns.set(style="whitegrid")
     #202431029_Jonathan Juan Setyanto
```

Penjelasan :
Cell ini digunakan untuk mengimpor beberapa library Python yang dibutuhkan dalam proses pengolahan data, analisis data (EDA), dan visualisasi.
Secara keseluruhan, cell ini berfungsi untuk mempersiapkan library yang diperlukan sebelum melakukan pengolahan dan analisis dataset. Pandas dan NumPy digunakan untuk pengolahan data, sedangkan Matplotlib dan Seaborn digunakan untuk menampilkan hasil analisis dalam bentuk visualisasi agar karakteristik dataset lebih mudah dipahami.

2. Baca Dataset

Baca Dataset

```
[2]: # Baca dataset
df = pd.read_csv("01_heart_disease.csv")

# Menampilkan 5 data teratas
df.head()
#202431029_Jonathan Juan Setyanto
```

[2]:

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
0	40	M	ATA	140	289	0	Normal	172	N	0.0	Up	0
1	49	F	NAP	160	180	0	Normal	156	N	1.0	Flat	1
2	37	M	ATA	130	283	0	ST	98	N	0.0	Up	0
3	48	F	ASY	138	214	0	Normal	108	Y	1.5	Flat	1
4	54	M	NAP	150	195	0	Normal	122	N	0.0	Up	0

Penjelasan :

Cell ini digunakan untuk membaca dataset dari file CSV dan menampilkan lima baris data pertama. Dataset yang digunakan adalah 01_heart_disease.csv, yang berisi informasi mengenai karakteristik pasien terkait penyakit jantung (Heart Disease).

- df = pd.read_csv("01_heart_disease.csv")
  Digunakan untuk membaca file dataset berformat CSV menggunakan fungsi read_csv() dari library Pandas. Data yang berhasil dibaca kemudian disimpan ke dalam variabel df dalam bentuk DataFrame agar dapat diolah dan dianalisis lebih lanjut.
- df.head()
  Digunakan untuk menampilkan lima baris pertama dari dataset. Perintah ini membantu melihat gambaran awal mengenai isi dataset, seperti nama kolom, nilai data, serta format atau tipe informasi yang tersedia.

3. Descriptive Analysis

Descriptive Analysis

```
[3]: # Info dataset: jumlah baris, kolom, tipe data, null
df.info()
#202431029_Jonathan Juan Setyanto
```

```
<class 'pandas.DataFrame'>
RangeIndex: 918 entries, 0 to 917
Data columns (total 12 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   Age             918 non-null    int64
 1   Sex             918 non-null    str
 2   ChestPainType   918 non-null    str
 3   RestingBP       918 non-null    int64
 4   Cholesterol     918 non-null    int64
 5   FastingBS       918 non-null    int64
 6   RestingECG      918 non-null    str
 7   MaxHR           918 non-null    int64
 8   ExerciseAngina  918 non-null    str
 9   Oldpeak         918 non-null    float64
 10  ST_Slope        918 non-null    str
 11  HeartDisease    918 non-null    int64
dtypes: float64(1), int64(6), str(5)
memory usage: 86.2 KB
```

Penjelasan :

Cell ini digunakan untuk mengetahui informasi umum mengenai struktur dataset melalui fungsi df.info(). Analisis ini merupakan bagian dari Exploratory Data Analysis (EDA) yang bertujuan untuk memeriksa jumlah data, jumlah atribut, tipe data, serta kelengkapan nilai pada setiap kolom.

- df.info()
  Merupakan fungsi dari Pandas yang digunakan untuk menampilkan ringkasan informasi dataset. Informasi yang ditampilkan meliputi jumlah

baris, jumlah kolom, nama atribut, jumlah data yang tidak kosong (Non-Null Count), tipe data (Data Type), serta penggunaan memori.

Berdasarkan hasil analisis menggunakan df.info(), dataset Heart Disease memiliki 918 baris dan 12 kolom dengan kondisi seluruh data terisi tanpa adanya nilai kosong. Dataset terdiri dari atribut numerik dan kategorikal sehingga perlu diperhatikan dalam proses pengolahan data sebelum diterapkan pada algoritma Machine Learning. Hasil pemeriksaan ini juga menunjukkan bahwa dataset sudah memiliki struktur yang cukup baik untuk dilanjutkan ke tahap analisis berikutnya.

```
[4]: # statistik deskriptif untuk semua kolom
df.describe(include="all")
#202431029_Jonathan Juan Setyanto
```

[4]:

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
count	918.000000	918	918	918.000000	918.000000	918.000000	918	918.000000	918	918.000000	918	918.000000
unique	NaN	2	4	NaN	NaN	NaN	3	NaN	2	NaN	3	NaN
top	NaN	M	ASY	NaN	NaN	NaN	Normal	NaN	N	NaN	Flat	NaN
freq	NaN	725	496	NaN	NaN	NaN	552	NaN	547	NaN	460	NaN
mean	53.510893	NaN	NaN	132.396514	198.799564	0.233115	NaN	136.809368	NaN	0.887364	NaN	0.553377
std	9.432617	NaN	NaN	18.514154	109.384145	0.423046	NaN	25.460334	NaN	1.066570	NaN	0.497414
min	28.000000	NaN	NaN	0.000000	0.000000	0.000000	NaN	60.000000	NaN	-2.600000	NaN	0.000000
25%	47.000000	NaN	NaN	120.000000	173.250000	0.000000	NaN	120.000000	NaN	0.000000	NaN	0.000000
50%	54.000000	NaN	NaN	130.000000	223.000000	0.000000	NaN	138.000000	NaN	0.600000	NaN	1.000000
75%	60.000000	NaN	NaN	140.000000	267.000000	0.000000	NaN	156.000000	NaN	1.500000	NaN	1.000000
max	77.000000	NaN	NaN	200.000000	603.000000	1.000000	NaN	202.000000	NaN	6.200000	NaN	1.000000

Penjelasan :

Cell ini digunakan untuk menampilkan ringkasan statistik deskriptif dari seluruh kolom yang terdapat dalam dataset. Perintah df.describe(include="all") digunakan untuk mengetahui gambaran umum data, baik yang memiliki tipe numerik maupun kategorikal.

- df.describe(include="all")
  Merupakan fungsi Pandas yang digunakan untuk menghasilkan statistik deskriptif dari seluruh atribut dataset. Parameter include="all" memungkinkan fungsi ini menampilkan informasi untuk kolom numerik maupun kategorikal.

Berdasarkan hasil statistik deskriptif, dataset memiliki 918 data dengan rata-rata usia pasien sebesar 53,51 tahun, tekanan darah 132,40, kadar kolesterol 198,80, dan detak jantung maksimum 136,81. Usia pasien berada pada rentang 28 hingga 77 tahun. Pada data kategorikal, jenis kelamin laki-laki (M) menjadi kategori terbanyak dengan 725 data, sedangkan jenis nyeri dada yang paling sering muncul adalah ASY sebanyak 496 data. Selain itu, kolom HeartDisease memiliki nilai rata-rata 0,553 yang menunjukkan bahwa sekitar 55,34% pasien dalam dataset termasuk dalam kategori penyakit jantung. Hasil ini memberikan gambaran awal mengenai distribusi dan karakteristik data yang akan dianalisis lebih lanjut.

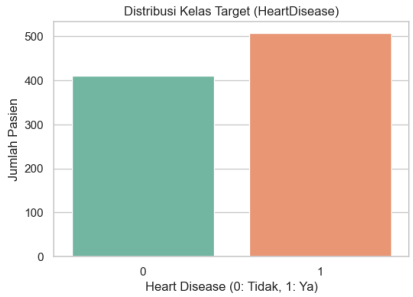
```
[5]: # statistik deskriptif untuk semua kolom
df.describe(include="all")

# Distribusi variabel target (HeartDisease: 0 = Negatif, 1 = Positif)
plt.figure(figsize=(6, 4))
sns.countplot(x="HeartDisease", data=df, palette="Set2")
plt.title("Distribusi Kelas Target (HeartDisease)")
plt.xlabel("Heart Disease (0: Tidak, 1: Ya)")
plt.ylabel("Jumlah Pasien")
plt.show()
#202431029_Jonathan Juan Setyanto
```

```
C:\Users\jjset\AppData\Local\Temp\ipykernel_25204\2993682021.py:6: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.1
same effect.

  sns.countplot(x="HeartDisease", data=df, palette="Set2")
```



Penjelasan :

Kode pada cell ini digunakan untuk menampilkan rangkuman statistik deskriptif seluruh kolom pada dataset serta memvisualisasikan persebaran variabel target (HeartDisease) dalam bentuk diagram batang (count plot) Seaborn untuk mengetahui perbandingan jumlah pasien terindikasi dan tidak terindikasi penyakit jantung.

Grafik tersebut memperlihatkan distribusi kelas target yang relatif seimbang, dengan rincian sekitar 410 pasien tidak menderita penyakit jantung (kategori 0) dan sekitar 508 pasien menderita penyakit jantung (kategori 1).

4. Adjustment of Variable Types

Adjustment of Variable

```
[6]: # Daftar kolom kategorikal pada dataset Heart Disease
categorical_cols = ["Sex", "ChestPainType", "FastingBS", "RestingECG", "ExerciseAngina", "ST_Slope"]

# Mengubah tipe data ke category
for col in categorical_cols:
    df[col] = df[col].astype("category")

df.dtypes
#202431029_Jonathan Juan Setyanto
```

```
[6]: Age                int64
Sex              category
ChestPainType    category
RestingBP           int64
Cholesterol         int64
FastingBS        category
RestingECG       category
MaxHR               int64
ExerciseAngina   category
Oldpeak           float64
ST_Slope         category
HeartDisease        int64
dtype: object
```

Penjelasan :

Kode pada cell ini digunakan untuk menyesuaikan tipe data beberapa atribut dalam dataset yang memiliki karakteristik kategorikal. Proses dilakukan dengan mengelompokkan nama kolom ke dalam variabel categorical_cols, kemudian menggunakan perulangan for dan fungsi astype("category") untuk mengubah tipe data kolom tersebut menjadi kategorikal. Setelah proses selesai, perintah df.dtypes digunakan untuk menampilkan tipe data seluruh kolom guna memastikan bahwa perubahan telah berhasil dilakukan.

Berdasarkan hasil output, enam atribut, yaitu Sex, ChestPainType, FastingBS, RestingECG, ExerciseAngina, dan ST_Slope berhasil diubah menjadi tipe data category, sedangkan atribut lainnya tetap menggunakan tipe data numerik (int64 dan float64). Penyesuaian ini bertujuan agar tipe data sesuai dengan karakteristik masing-masing variabel sehingga mempermudah proses analisis dan pengolahan dataset pada tahap selanjutnya.

5. Detection and Treatment of Missing Data

Detection and Treatment of Missing Data

```
[7]: # Cek jumlah nilai hilang (missing value) per kolom
print("Jumlah Missing Values:")
print(df.isnull().sum())
#202431029_Jonathan Juan Setyanto
```

```
Jumlah Missing Values:
Age             0
Sex             0
ChestPainType   0
RestingBP       0
Cholesterol     0
FastingBS       0
RestingECG      0
MaxHR           0
ExerciseAngina  0
Oldpeak         0
ST_Slope        0
HeartDisease    0
dtype: int64
```

Penjelasan :

Kode pada cell ini digunakan untuk memeriksa keberadaan nilai kosong (missing value) pada setiap kolom dalam dataset. Fungsi df.isnull().sum() digunakan untuk mendeteksi dan menghitung jumlah nilai kosong pada masing-masing atribut, sedangkan fungsi print() digunakan untuk menampilkan hasil pemeriksaan tersebut.

Berdasarkan hasil output, seluruh 12 atribut dalam dataset menunjukkan nilai 0, yang berarti tidak ditemukan adanya missing value pada setiap kolom. Dengan demikian, dataset sudah memiliki kelengkapan data yang baik sehingga tidak diperlukan proses penanganan nilai kosong seperti penghapusan data maupun imputasi.

6. Identification of Atypical Data (Outliers)

Identification of Atypical Data (Outliers)

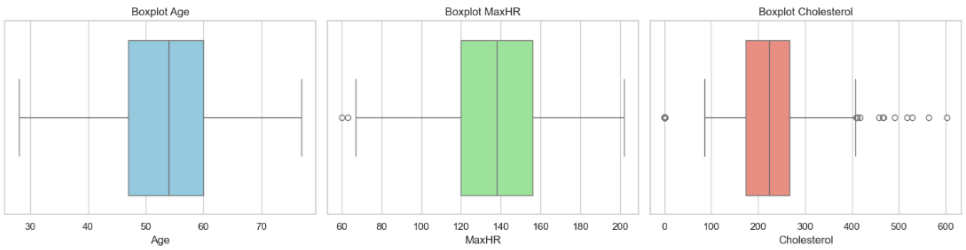
```
[8]: # Visualisasi boxplot untuk variabel numerik (Age, MaxHR, RestingBP, Cholesterol, Oldpeak)
fig, axes = plt.subplots(1, 3, figsize=(15, 4))

sns.boxplot(x=df["Age"], ax=axes[0], color="skyblue")
axes[0].set_title("Boxplot Age")

sns.boxplot(x=df["MaxHR"], ax=axes[1], color="lightgreen")
axes[1].set_title("Boxplot MaxHR")

sns.boxplot(x=df["Cholesterol"], ax=axes[2], color="salmon")
axes[2].set_title("Boxplot Cholesterol")

plt.tight_layout()
plt.show()
#202431029_Jonathan Juan Setyanto
```



Penjelasan :

Kode pada cell ini digunakan untuk memvisualisasikan tiga variabel numerik (Age, MaxHR, dan Cholesterol) secara sejajar dalam satu tata letak (subplot 1x3) menggunakan boxplot guna mendeteksi keberadaan outlier (data pencilan) pada masing-masing fitur.

Hasil boxplot menunjukkan bahwa variabel Age tidak memiliki outlier, variabel MaxHR memiliki sedikit outlier di batas bawah (sekitar nilai 60), sedangkan variabel Cholesterol memiliki banyak outlier signifikan, baik pada nilai 0 di batas bawah maupun rentang nilai tinggi antara 400 hingga 600 pada batas atas.

[9]:
```
# Deteksi outlier pada kolom Age menggunakan Metode IQR
Q1 = df["Age"].quantile(0.25)
Q3 = df["Age"].quantile(0.75)
IQR = Q3 - Q1

outliers = df[(df["Age"] < Q1 - 1.5 * IQR) | (df["Age"] > Q3 + 1.5 * IQR)]
print("Jumlah outlier pada kolom Age:", len(outliers))
#202431029_Jonathan Juan Setyanto
```

```
Jumlah outlier pada kolom Age: 0
```

Penjelasan :

Kode pada cell ini digunakan untuk mendeteksi keberadaan data pencilan (outlier) pada kolom Age menggunakan metode Interquartile Range (IQR). Proses dilakukan dengan menghitung nilai kuartil pertama (Q1) dan kuartil ketiga (Q3), kemudian mencari selisih keduanya untuk memperoleh nilai IQR. Selanjutnya, data yang memiliki nilai di bawah batas bawah atau di atas batas atas IQR akan diidentifikasi sebagai outlier. Perintah len(outliers) digunakan untuk menghitung jumlah data pencilan yang ditemukan, sedangkan print() menampilkan hasil perhitungannya.

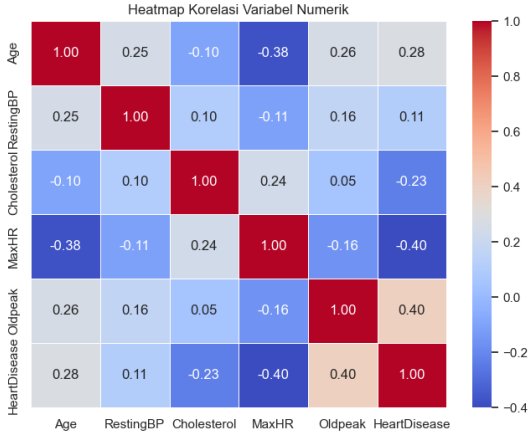
Output dari kode ini menunjukkan jumlah data pencilan (outlier) yang ditemukan pada kolom Age. Hasil tersebut digunakan untuk mengetahui apakah terdapat usia pasien yang memiliki nilai terlalu jauh dari distribusi mayoritas data. Jika tidak ditemukan outlier, berarti seluruh nilai usia masih berada dalam rentang batas yang ditentukan oleh metode IQR.

7. Correlation of Variables

Correlation of Variables

[10]:
```
# Filter variabel numerik saja
numeric_df = df.select_dtypes(include=["int64", "float64"])

# Heatmap korelasi antar variabel numerik
plt.figure(figsize=(8, 6))
sns.heatmap(numeric_df.corr(), annot=True, cmap="coolwarm", fmt=".2f", linewidths=0.5)
plt.title("Heatmap Korelasi Variabel Numerik")
plt.show()
#202431029_Jonathan Juan Setyanto
```



Penjelasan :

Kode pada cell ini digunakan untuk menyaring seluruh variabel numerik dalam dataset dan memvisualisasikan matriks korelasinya menggunakan heatmap Seaborn guna menganalisis tingkat serta arah hubungan linear antarfitur, khususnya terhadap variabel target (HeartDisease).

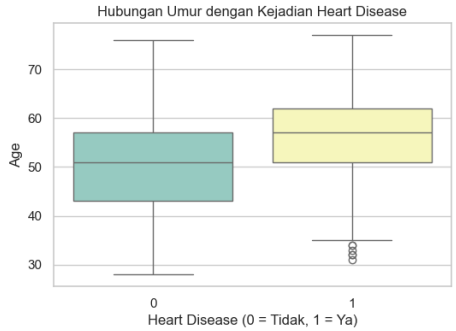
Visualisasi *heatmap* menunjukkan bahwa variabel Oldpeak (0.40) dan Age (0.28) memiliki korelasi positif paling signifikan terhadap HeartDisease, sementara MaxHR (-0.40) menunjukkan korelasi negatif yang paling kuat, tanpa terdapat indikasi multikolinearitas tinggi antarvariabel independen.

[11]:
```
# Hubungan Umur (Age) dengan kejadian Penyakit Jantung (HeartDisease)
plt.figure(figsize=(6, 4))
sns.boxplot(x="HeartDisease", y="Age", data=df, palette="Set3")
plt.title("Hubungan Umur dengan Kejadian Heart Disease")
plt.xlabel("Heart Disease (0 = Tidak, 1 = Ya)")
plt.ylabel("Age")
plt.show()
#202431029_Jonathan Juan Setyanto
```

```
C:\Users\jjset\AppData\Local\Temp\ipykernel_11252\3567742284.py:3: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0
same effect.

  sns.boxplot(x="HeartDisease", y="Age", data=df, palette="Set3")
```



Penjelasan :

Kode pada cell ini digunakan untuk memvisualisasikan perbandingan distribusi usia (Age) antara pasien yang tidak menderita dan menderita penyakit jantung (HeartDisease) menggunakan boxplot Seaborn.

Hasil boxplot menunjukkan bahwa pasien yang menderita penyakit jantung (kategori 1) cenderung berusia lebih tua dengan median sekitar 57 tahun dibandingkan pasien yang tidak menderita (median sekitar 51 tahun), meskipun terdapat beberapa data pencilan (outliers) berusia muda di kisaran 30 hingga 35 tahun pada kelompok penderita penyakit jantung.

3.2 Preprocessing

PREPROCESSING

[12]:
```
df = pd.read_csv('01_heart_disease.csv', sep=",") #import dataset, sep itu separator bisa , ; (sesuai sama datasetnya)
df
#202431029_Jonathan Juan Setyanto
```

[12]:

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
0	40	M	ATA	140	289	0	Normal	172	N	0.0	Up	0
1	49	F	NAP	160	180	0	Normal	156	N	1.0	Flat	1
2	37	M	ATA	130	283	0	ST	98	N	0.0	Up	0
3	48	F	ASY	138	214	0	Normal	108	Y	1.5	Flat	1
4	54	M	NAP	150	195	0	Normal	122	N	0.0	Up	0
...	...	...	...	...	...	...	...	...	...	...	...	...
913	45	M	TA	110	264	0	Normal	132	N	1.2	Flat	1
914	68	M	ASY	144	193	1	Normal	141	N	3.4	Flat	1
915	57	M	ASY	130	131	0	Normal	115	Y	1.2	Flat	1
916	57	F	ATA	130	236	0	LVH	174	N	0.0	Flat	1
917	38	M	NAP	138	175	0	Normal	173	N	0.0	Up	0

918 rows × 12 columns

Penjelasan :

Kode pada cell ini digunakan untuk memuat dataset 01_heart_disease.csv ke dalam DataFrame menggunakan fungsi pd.read_csv() dengan pemisah koma (,) serta menampilkan gambaran umum isi tabel data tersebut untuk memulai tahap preprocessing.

Output tersebut menampilkan pratinjau tabel dataset penyakit jantung yang terdiri dari total 918 baris data dan 12 kolom fitur numerik maupun kategorikal (termasuk variabel target HeartDisease).

```
[13]: df.info() #info buat tau jumlah data sama tipedatanya
      #202431029_Jonathan Juan Setyanto
```

```
<class 'pandas.DataFrame'>
RangeIndex: 918 entries, 0 to 917
Data columns (total 12 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   Age             918 non-null    int64
 1   Sex             918 non-null    str
 2   ChestPainType   918 non-null    str
 3   RestingBP       918 non-null    int64
 4   Cholesterol     918 non-null    int64
 5   FastingBS       918 non-null    int64
 6   RestingECG      918 non-null    str
 7   MaxHR           918 non-null    int64
 8   ExerciseAngina  918 non-null    str
 9   Oldpeak         918 non-null    float64
 10  ST_Slope        918 non-null    str
 11  HeartDisease    918 non-null    int64
dtypes: float64(1), int64(6), str(5)
memory usage: 86.2 KB
```

Penjelasan :

Kode pada cell ini digunakan untuk menampilkan ringkasan informasi struktur DataFrame df, seperti jumlah entri data, daftar nama kolom beserta jumlah nilai non-null (untuk memeriksa ketersediaan missing value), tipe data dari masing-masing kolom, serta alokasi penggunaan memori.

Output tersebut memperlihatkan ringkasan struktur dataset yang berisi 918 baris dan 12 kolom tanpa adanya missing value, yang terbagi ke dalam tipe data float64 (1 kolom), int64 (6 kolom), dan str (5 kolom) dengan penggunaan memori sebesar 86.2 KB.

```
[14]: df['Sex'].unique() #nyari nilai unik, kalau muncul berulang di dataset, disini munculnya 1
      #202431029_Jonathan Juan Setyanto
```

```
[14]: <StringArray>
      ['M', 'F']
      Length: 2, dtype: str
```

Penjelasan :

Kode pada cell ini digunakan untuk mengambil dan menampilkan seluruh nilai unik yang terdapat pada kolom Sex dalam DataFrame df guna memeriksa variasi nilai kategori jenis kelamin yang tersimpan pada dataset.

Output tersebut memperlihatkan bahwa kolom Sex memiliki 2 nilai unik bertipe data string, yaitu 'M' (Male) dan 'F' (Female).

```
[15]: df['ChestPainType'].unique() #nyari tipe nyeri dada unik, kalau muncul berulang di dataset, disini munculnya 1
      #202431029_Jonathan Juan Setyanto
```

```
[15]: <StringArray>
      ['ATA', 'NAP', 'ASY', 'TA']
      Length: 4, dtype: str
```

Penjelasan :

Kode pada cell ini digunakan untuk mengambil dan menampilkan seluruh nilai unik yang terdapat pada kolom ChestPainType dalam DataFrame df guna memeriksa variasi jenis/tipe nyeri dada yang tersimpan pada dataset.

Output tersebut memperlihatkan bahwa kolom ChestPainType memiliki 4 nilai unik bertipe data string, yaitu 'ATA', 'NAP', 'ASY', dan 'TA'.

```
[16]: from sklearn.preprocessing import LabelEncoder
      #202431029_Jonathan Juan Setyanto

      le = LabelEncoder() #fungsi buat ngubah kategorikal (objek/ string) jadi numerik

      # Daftar kolom kategorikal teks pada dataset heart disease
      categorical_cols = ['Sex', 'ChestPainType', 'RestingECG', 'ExerciseAngina', 'ST_Slope']

      for col in categorical_cols:
          df[col] = le.fit_transform(df[col]) #nyari nilai unik trus disimpan di le.classes_ trus diubah ke numerik
          print(f"--- {col} ---")
          print(df[col].unique()) #cek nilai unik apakah dah berubah jadi angka
          for i, label in enumerate(le.classes_):
              print(f"{i} = {label}") #looping buat munculin angka dari transform sama label aslinya yg kategorikal
          print()
```

```
--- Sex ---
[1 0]
0 = F
1 = M

--- ChestPainType ---
[1 2 0 3]
0 = ASY
1 = ATA
2 = NAP
3 = TA

--- RestingECG ---
[1 2 0]
0 = LVH
1 = Normal
2 = ST

--- ExerciseAngina ---
[0 1]
0 = N
1 = Y

--- ST_Slope ---
[2 1 0]
0 = Down
1 = Flat
2 = Up
```

Penjelasan :

Kode pada cell ini digunakan untuk mengodekan (encoding) seluruh kolom kategorikal bertipe teks (Sex, ChestPainType, RestingECG, ExerciseAngina, dan ST_Slope) menjadi nilai numerik menggunakan LabelEncoder dari scikit-learn serta menampilkan daftar pemetaan (mapping) antara angka dengan label aslinya.

Output tersebut memperlihatkan hasil transformasi variabel kategorikal menjadi angka beserta pemetannya, yaitu Sex (0=F, 1=M), ChestPainType (0=ASY, 1=ATA, 2=NAP, 3=TA), RestingECG (0=LVH, 1=Normal, 2=ST), ExerciseAngina (0=N, 1=Y), dan ST_Slope (0=Down, 1=Flat, 2=Up)

[17]:
```
df
#202431029_Jonathan Juan Setyanto
```

[17]:

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
0	40	1	1	140	289	0	1	172	0	0.0	2	0
1	49	0	2	160	180	0	1	156	0	1.0	1	1
2	37	1	1	130	283	0	2	98	0	0.0	2	0
3	48	0	0	138	214	0	1	108	1	1.5	1	1
4	54	1	2	150	195	0	1	122	0	0.0	2	0
...	...	...	...	...	...	...	...	...	...	...	...	...
913	45	1	3	110	264	0	1	132	0	1.2	1	1
914	68	1	0	144	193	1	1	141	0	3.4	1	1
915	57	1	0	130	131	0	1	115	1	1.2	1	1
916	57	0	1	130	236	0	0	174	0	0.0	1	1
917	38	1	2	138	175	0	1	173	0	0.0	2	0

918 rows × 12 columns

Penjelasan :

Kode pada cell ini digunakan untuk menampilkan kembali pratinjau DataFrame df guna memverifikasi bahwa seluruh kolom kategorikal telah berhasil ditransformasi menjadi bentuk numerik setelah proses label encoding.

Output tersebut menampilkan pratinjau tabel dataset sebanyak 918 baris dan 12 kolom yang seluruh fiturnya kini sudah berupa data numerik dan siap digunakan untuk tahap pemodelan machine learning.

3.3 Naive Bayes

NAIVE BAYES

[18]:
```
data = pd.read_csv('01_heart_disease.csv')
data
#202431029_Jonathan Juan Setyanto
```

[18]:

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
0	40	M	ATA	140	289	0	Normal	172	N	0.0	Up	0
1	49	F	NAP	160	180	0	Normal	156	N	1.0	Flat	1
2	37	M	ATA	130	283	0	ST	98	N	0.0	Up	0
3	48	F	ASY	138	214	0	Normal	108	Y	1.5	Flat	1
4	54	M	NAP	150	195	0	Normal	122	N	0.0	Up	0
...	...	...	...	...	...	...	...	...	...	...	...	...
913	45	M	TA	110	264	0	Normal	132	N	1.2	Flat	1
914	68	M	ASY	144	193	1	Normal	141	N	3.4	Flat	1
915	57	M	ASY	130	131	0	Normal	115	Y	1.2	Flat	1
916	57	F	ATA	130	236	0	LVH	174	N	0.0	Flat	1
917	38	M	NAP	138	175	0	Normal	173	N	0.0	Up	0

918 rows × 12 columns

Penjelasan :

Kode pada cell ini digunakan untuk memuat ulang dataset 01_heart_disease.csv ke dalam variabel data dan menampilkan pratinjaunya sebagai langkah awal persiapan data sebelum menerapkan metode Naive Bayes.

Output tersebut menampilkan pratinjau tabel dataset berukuran 918 baris dan 12 kolom yang masih berisi fitur-fitur kategorikal asli untuk diproses dalam alur pemodelan Naive Bayes.

```
[19]: data.head()
      #202431029_Jonathan Juan Setyanto
```

[19]:

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
0	40	M	ATA	140	289	0	Normal	172	N	0.0	Up	0
1	49	F	NAP	160	180	0	Normal	156	N	1.0	Flat	1
2	37	M	ATA	130	283	0	ST	98	N	0.0	Up	0
3	48	F	ASY	138	214	0	Normal	108	Y	1.5	Flat	1
4	54	M	NAP	150	195	0	Normal	122	N	0.0	Up	0

Penjelasan :

Kode pada cell ini digunakan untuk menampilkan 5 baris teratas dari DataFrame data menggunakan fungsi head() guna memeriksa pratinjau ringkas isi tabel data.

Output tersebut menampilkan 5 sampel data pertama (indeks 0 hingga 4) beserta seluruh 12 kolom variabelnya untuk memastikan struktur data termuat dengan benar.

```
[20]: data.info()
      #202431029_Jonathan Juan Setyanto
```

```
<class 'pandas.DataFrame'>
RangeIndex: 918 entries, 0 to 917
Data columns (total 12 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   Age             918 non-null    int64
 1   Sex             918 non-null    str
 2   ChestPainType   918 non-null    str
 3   RestingBP       918 non-null    int64
 4   Cholesterol     918 non-null    int64
 5   FastingBS       918 non-null    int64
 6   RestingECG      918 non-null    str
 7   MaxHR           918 non-null    int64
 8   ExerciseAngina  918 non-null    str
 9   Oldpeak         918 non-null    float64
 10  ST_Slope        918 non-null    str
 11  HeartDisease    918 non-null    int64
dtypes: float64(1), int64(6), str(5)
memory usage: 86.2 KB
```

Penjelasan :

Kode pada cell ini digunakan untuk menampilkan ringkasan informasi struktur DataFrame data, meliputi jumlah baris, daftar nama kolom, keberadaan nilai non-null (mengecek missing value), tipe data tiap variabel, serta alokasi penggunaan memori.

Output tersebut memperlihatkan ringkasan struktur dataset yang terdiri dari 918 baris dan 12 kolom tanpa missing value, dengan rincian tipe data float64 (1 kolom), int64 (6 kolom), dan str (5 kolom) serta penggunaan memori sebesar 86.2 KB.

```
[21]: data.describe()
      #202431029_Jonathan Juan Setyanto
```

[21]:

	Age	RestingBP	Cholesterol	FastingBS	MaxHR	Oldpeak	HeartDisease
count	918.000000	918.000000	918.000000	918.000000	918.000000	918.000000	918.000000
mean	53.510893	132.396514	198.799564	0.233115	136.809368	0.887364	0.553377
std	9.432617	18.514154	109.384145	0.423046	25.460334	1.066570	0.497414
min	28.000000	0.000000	0.000000	0.000000	60.000000	-2.600000	0.000000
25%	47.000000	120.000000	173.250000	0.000000	120.000000	0.000000	0.000000
50%	54.000000	130.000000	223.000000	0.000000	138.000000	0.600000	1.000000
75%	60.000000	140.000000	267.000000	0.000000	156.000000	1.500000	1.000000
max	77.000000	200.000000	603.000000	1.000000	202.000000	6.200000	1.000000

Penjelasan :

Kode pada cell ini digunakan untuk menghitung dan menampilkan ringkasan statistik deskriptif (seperti jumlah sampel, rata-rata, standar deviasi, nilai minimum, kuartil, dan nilai maksimum) dari seluruh kolom numerik pada DataFrame data.

Output tersebut menampilkan ringkasan statistik deskriptif dari 918 entri data pada 7 variabel numerik (Age, RestingBP, Cholesterol, FastingBS, MaxHR, Oldpeak, dan HeartDisease) yang memuat informasi rata-rata, sebaran data (standar deviasi), rentang nilai minimum dan maksimum, serta nilai kuartil untuk setiap fitur.

[22]:
```
for col in data.columns:
    if data[col].dtype == 'string':
        data[col] = data[col].astype('object')
        #202431029_Jonathan Juan Setyanto
```

Penjelasan :

Kode pada cell ini digunakan untuk mengiterasi seluruh kolom pada DataFrame data dan mengonversi tipe data dari kolom yang bertipe 'string' menjadi 'object' guna memastikan kompatibilitas tipe data pada proses analisis atau pemodelan berikutnya.

Cell ini tidak menghasilkan output teks maupun visual di layar karena hanya menjalankan operasi pengubahan tipe data kolom secara internal di dalam memori.

[23]:
```
numerical_features = [feature for feature in data.columns if data[feature].dtypes != 'O']
print("jumlah fitur numerik = ", len(numerical_features))
print("daftar fitur numerik =", (numerical_features))
display(data[numerical_features].head())
#202431029_Jonathan Juan Setyanto
```

```
jumlah fitur numerik =  7
daftar fitur numerik = ['Age', 'RestingBP', 'Cholesterol', 'FastingBS', 'MaxHR', 'Oldpeak', 'HeartDisease']
```

	Age	RestingBP	Cholesterol	FastingBS	MaxHR	Oldpeak	HeartDisease
0	40	140	289	0	172	0.0	0
1	49	160	180	0	156	1.0	1
2	37	130	283	0	98	0.0	0
3	48	138	214	0	108	1.5	1
4	54	150	195	0	122	0.0	0

Penjelasan :

Kode pada cell ini digunakan untuk mengidentifikasi dan memisahkan seluruh kolom yang bertipe data numerik (bukan tipe 'O'/object), mencetak jumlah serta daftar nama fiturnya, dan menampilkan 5 baris pertama dari data numerik tersebut.

Output tersebut memperlihatkan bahwa terdapat 7 fitur numerik di dalam dataset (Age, RestingBP, Cholesterol, FastingBS, MaxHR, Oldpeak, dan HeartDisease) beserta pratinjau 5 baris awal datanya.

[24]:
```
categorical_features = [feature for feature in data.columns if data[feature].dtypes == 'O']
print("jumlah fitur categorical = ", len(categorical_features))
print("daftar fitur categorical =", (categorical_features))
display(data[categorical_features].head())
#202431029_Jonathan Juan Setyanto
```

```
jumlah fitur categorical =  5
daftar fitur categorical = ['Sex', 'ChestPainType', 'RestingECG', 'ExerciseAngina', 'ST_Slope']
```

	Sex	ChestPainType	RestingECG	ExerciseAngina	ST_Slope
0	M	ATA	Normal	N	Up
1	F	NAP	Normal	N	Flat
2	M	ATA	ST	N	Up
3	F	ASY	Normal	Y	Flat
4	M	NAP	Normal	N	Up

Penjelasan :

Kode pada cell ini digunakan untuk mengidentifikasi dan memisahkan seluruh kolom yang bertipe data kategorikal ('O'/object), mencetak jumlah serta daftar nama fiturnya, dan menampilkan 5 baris pertama dari data kategorikal tersebut.

Output tersebut memperlihatkan bahwa terdapat 5 fitur kategorikal di dalam dataset (Sex, ChestPainType, RestingECG, ExerciseAngina, dan ST_Slope) beserta pratinjau 5 baris awal datanya.

[25]:
```
for i in categorical_features:
    print(data[i].unique())
    #202431029_Jonathan Juan Setyanto
```

```
['M' 'F']
['ATA' 'NAP' 'ASY' 'TA']
['Normal' 'ST' 'LVH']
['N' 'Y']
['Up' 'Flat' 'Down']
```

Penjelasan :

Kode pada cell ini digunakan untuk mengiterasi seluruh kolom dalam categorical_features dan mencetak daftar nilai unik dari masing-masing kolom kategorikal tersebut.

Output tersebut menampilkan daftar nilai unik dari kelima fitur kategorikal secara berurutan, yaitu jenis kelamin (['M' 'F']), tipe nyeri dada (['ATA' 'NAP' 'ASY' 'TA']), hasil EKG istirahat (['Normal' 'ST' 'LVH']), angina akibat olahraga (['N' 'Y']), serta kemiringan segmen ST (['Up' 'Flat' 'Down']).

[26]:
```
from sklearn.preprocessing import LabelEncoder

label_encoder = LabelEncoder()
for feature in categorical_features:
    print(data[feature].unique())
    data[feature] = label_encoder.fit_transform(data[feature])
    print(data[feature].unique())
    #202431029_Jonathan Juan Setyanto
```

```
['M' 'F']
[1 0]
['ATA' 'NAP' 'ASY' 'TA']
[1 2 0 3]
['Normal' 'ST' 'LVH']
[1 2 0]
['N' 'Y']
[0 1]
['Up' 'Flat' 'Down']
[2 1 0]
```

Penjelasan :

Kode pada cell ini digunakan untuk mengodekan (encoding) seluruh kolom kategorikal menjadi nilai numerik menggunakan LabelEncoder dari scikit-learn sekaligus mencetak daftar nilai unik sebelum dan sesudah proses pengodean untuk setiap fitur.

Output tersebut memperlihatkan perbandingan nilai unik untuk kelima fitur kategorikal sebelum dan sesudah ditransformasikan menjadi representasi angka numerik, seperti 'M'/'F' menjadi 1/0 dan 'Up'/'Flat'/'Down' menjadi 2/1/0.

[27]:
```
data.head()
#202431029_Jonathan Juan Setyanto
```

[27]:

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
0	40	1	1	140	289	0	1	172	0	0.0	2	0
1	49	0	2	160	180	0	1	156	0	1.0	1	1
2	37	1	1	130	283	0	2	98	0	0.0	2	0
3	48	0	0	138	214	0	1	108	1	1.5	1	1
4	54	1	2	150	195	0	1	122	0	0.0	2	0

Penjelasan :

Kode pada cell ini digunakan untuk menampilkan 5 baris pertama dari DataFrame data menggunakan fungsi head() guna memverifikasi bahwa seluruh kolom kategorikal telah berhasil ditransformasikan menjadi bentuk numerik setelah proses label encoding.

Output tersebut menampilkan pratinjau 5 sampel data pertama (indeks 0 hingga 4) dari 12 kolom yang seluruh fiturnya kini sudah sepenuhnya berbentuk angka numerik sehingga siap diproses dalam pemodelan algoritma Naive Bayes.

[28]:
```
x = data.drop(['HeartDisease'], axis=1)
y = data['HeartDisease']
#202431029_Jonathan Juan Setyanto
```

Penjelasan :

Kode pada cell ini digunakan untuk memisahkan dataset menjadi variabel fitur/independen (x) dengan menghapus kolom 'HeartDisease' dan variabel

target/dependen (y) yang mengambil kolom 'HeartDisease' sebagai persiapan sebelum proses pembagian data latih dan uji.

Cell ini tidak menghasilkan output teks maupun visual di layar karena operasi pemisahan variabel fitur dan target dilakukan dan disimpan secara internal di dalam memori.

```
[29]: x
      #202431029_Jonathan Juan Setyanto
```

[29]:

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope
0	40	1	1	140	289	0	1	172	0	0.0	2
1	49	0	2	160	180	0	1	156	0	1.0	1
2	37	1	1	130	283	0	2	98	0	0.0	2
3	48	0	0	138	214	0	1	108	1	1.5	1
4	54	1	2	150	195	0	1	122	0	0.0	2
...	...	...	...	...	...	...	...	...	...	...	...
913	45	1	3	110	264	0	1	132	0	1.2	1
914	68	1	0	144	193	1	1	141	0	3.4	1
915	57	1	0	130	131	0	1	115	1	1.2	1
916	57	0	1	130	236	0	0	174	0	0.0	1
917	38	1	2	138	175	0	1	173	0	0.0	2

918 rows × 11 columns

Penjelasan :

Kode pada cell ini digunakan untuk menampilkan matriks variabel fitur/independen (x) yang telah dipisahkan dari variabel target (HeartDisease) guna memverifikasi kelengkapan data dan struktur kolom prediktor.

Output tersebut menampilkan pratinjau tabel matriks fitur sebanyak 918 baris dan 11 kolom yang seluruh nilainya berupa data numerik tanpa menyertakan kolom target.

```
[30]: y
      #202431029_Jonathan Juan Setyanto
```

```
[30]: 0      0
      1      1
      2      0
      3      1
      4      0
            ..
      913    1
      914    1
      915    1
      916    1
      917    0
      Name: HeartDisease, Length: 918, dtype: int64
```

Penjelasan :

Kode pada cell ini digunakan untuk menampilkan isi dari variabel target (y) yang memuat kolom HeartDisease guna memverifikasi nilai label kelas yang telah dipisahkan dari fitur prediktor.

Output tersebut menampilkan Series Pandas dari variabel target HeartDisease sebanyak 918 entri data dengan tipe data int64, yang berisi label klasifikasi biner 0 dan 1.

```
[31]: from sklearn.model_selection import train_test_split

x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.25, random_state=0)
#202431029_Jonathan Juan Setyanto
```

Penjelasan :

Kode pada cell ini digunakan untuk membagi variabel fitur (x) dan target (y) menjadi data latih (training set) dan data uji (testing set) dengan proporsi 75% untuk data latih dan 25% untuk data uji (test_size=0.25) menggunakan train_test_split dari scikit-learn serta menetapkan random_state=0 agar pembagian data bersifat konsisten (reproducible).

Cell ini tidak menghasilkan output teks maupun visual di layar karena proses pemisahan data latih (x_train, y_train) dan data uji (x_test, y_test) dilakukan secara internal di dalam memori.

```
[32]: from sklearn.naive_bayes import GaussianNB

model = GaussianNB()
model.fit(x_train, y_train)
#202431029_Jonathan Juan Setyanto
```

```
[32]: GaussianNB
      ▸ Parameters
```

Penjelasan :

Kode pada cell ini digunakan untuk mengimpor algoritma GaussianNB dari pustaka scikit-learn, menginisialisasi model klasifikasi Naive Bayes, dan melatih (fitting) model tersebut menggunakan pasangan data latih (x_train dan y_train).

Output tersebut menampilkan konfirmasi visual representasi objek GaussianNB yang menandakan bahwa proses pelatihan model klasifikasi Naive Bayes telah selesai dilakukan dengan parameter standar

```
[33]: y_pred_train = model.predict(x_train)
      y_pred_test = model.predict(x_test)
      #202431029_Jonathan Juan Setyanto
```

Penjelasan :

Kode pada cell ini digunakan untuk melakukan prediksi kelas target menggunakan model Naive Bayes yang telah dilatih, baik pada data latih (x_train) maupun data uji (x_test), yang hasilnya disimpan ke dalam variabel prediksi masing-masing.

Cell ini tidak menghasilkan output teks maupun visual di layar karena nilai hasil prediksi (y_pred_train dan y_pred_test) disimpan secara internal di dalam memori.

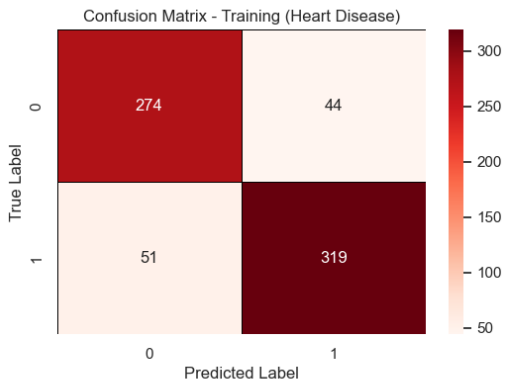
[34]:
```
from sklearn.metrics import confusion_matrix, classification_report
import numpy as np

# --- EVALUASI DATA TRAINING ---
cm_train = confusion_matrix(y_train, y_pred_train)

print("Evaluasi Training: ")
plt.figure(figsize=(6, 4))
sns.heatmap(
    cm_train,
    annot=True,
    fmt='d',
    cmap='Reds',
    linewidths=0.5,
    linecolor='black',
    xticklabels=[0, 1],
    yticklabels=[0, 1]
)
plt.title("Confusion Matrix - Training (Heart Disease)")
plt.xlabel("Predicted Label")
plt.ylabel("True Label")
plt.show()
plt.close()

# --- EVALUASI DATA TEST ---
cm_test = confusion_matrix(y_test, y_pred_test)
print("\nEvaluasi Test: ")
print(cm_test)
print(classification_report(y_test, y_pred_test, zero_division=0))
#202431029_Jonathan Juan Setyanto
```

```
Evaluasi Training:
```




```
Evaluasi Test:
[[ 73  19]
 [ 16 122]]
              precision    recall  f1-score   support

           0       0.82      0.79      0.81        92
           1       0.87      0.88      0.87       138

    accuracy                           0.85       230
   macro avg       0.84      0.84      0.84       230
weighted avg       0.85      0.85      0.85       230
```

Penjelasan :

Kode pada cell ini digunakan untuk mengevaluasi performa pemodelan Naive Bayes dengan menghitung matriks konfusi (confusion matrix) serta memvisualisasikannya ke dalam bentuk heatmap pada data latih, sekaligus menghitung matriks konfusi dan mencetak laporan klasifikasi (classification report) lengkap untuk data uji.

Hasil evaluasi menunjukkan bahwa model Naive Bayes berhasil mencapai tingkat akurasi sebesar 85% pada data uji dengan mengklasifikasikan secara tepat 73 sampel pasien non-penyakit jantung dan 122 sampel pasien penderita penyakit jantung, serta memperoleh skor f1-score sebesar 87% untuk deteksi kelas positif.

[35]:
```
# Memasukkan 11 nilai fitur sampel [Age, Sex, ChestPainType, RestingBP, Cholesterol, FastingBS, RestingECG, MaxHR, ExerciseAngina, Oldpeak, ST_Slope]
new_patient = np.array([[40, 1, 0, 140, 289, 0, 1, 172, 0, 0.0, 2]])
prediction = model.predict(new_patient)
print("Hasil prediksi penyakit jantung:", prediction[0]) #202431029_Jonathan Juan Setyanto
```

```
Hasil prediksi penyakit jantung: 0
C:\Users\jjset\AppData\Local\Programs\Python\Python313\Lib\site-packages\sklearn\utils\validation.py:2691: UserWarning: X does not have valid feature n
ames, but GaussianNB was fitted with feature names
  warnings.warn(
```

Penjelasan :

Kode pada cell ini digunakan untuk melakukan simulasi prediksi terhadap data sampel pasien baru dengan memasukkan 11 nilai fitur ke dalam model Naive Bayes yang telah dilatih serta menampilkan hasil prediksinya.

Output tersebut menunjukkan bahwa sampel pasien baru diprediksi masuk ke dalam kelas 0 (tidak menderita penyakit jantung), disertai peringatan (UserWarning) karena data input dimasukkan dalam bentuk array NumPy tanpa menyertakan nama kolom fitur.

3.4 Decision Tree

DECISION TREE

```
[36]: x = df.drop(['HeartDisease'], axis=1) #karna pakenya fitur numerik buat X (independent), axis = 1 buat yg di drop
      #202431029_Jonathan Juan Setyanto
```

Penjelasan :

Kode pada cell ini digunakan untuk memisahkan matriks variabel fitur/independen (x) dari DataFrame df dengan menghapus kolom target 'HeartDisease' (menggunakan axis=1) sebagai langkah awal persiapan data untuk pemodelan Decision Tree.

Cell ini tidak menghasilkan output teks maupun visual di layar karena operasi pemisahan variabel fitur dilakukan dan disimpan secara internal di dalam memori.

```
[37]: x
      #202431029_Jonathan Juan Setyanto
```

[37]:

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope
0	40	1	1	140	289	0	1	172	0	0.0	2
1	49	0	2	160	180	0	1	156	0	1.0	1
2	37	1	1	130	283	0	2	98	0	0.0	2
3	48	0	0	138	214	0	1	108	1	1.5	1
4	54	1	2	150	195	0	1	122	0	0.0	2
...	...	...	...	...	...	...	...	...	...	...	...
913	45	1	3	110	264	0	1	132	0	1.2	1
914	68	1	0	144	193	1	1	141	0	3.4	1
915	57	1	0	130	131	0	1	115	1	1.2	1
916	57	0	1	130	236	0	0	174	0	0.0	1
917	38	1	2	138	175	0	1	173	0	0.0	2

918 rows × 11 columns

Penjelasan :

Kode pada cell ini digunakan untuk menampilkan matriks variabel fitur/independen (x) yang telah dipisahkan dari variabel target guna memverifikasi kelengkapan dan struktur data sebelum pemodelan Decision Tree.

Output tersebut menampilkan pratinjau tabel matriks fitur berukuran 918 baris dan 11 kolom numerik tanpa menyertakan kolom target HeartDisease.

```
[38]: y = df['HeartDisease'] #y nya atau targetnya atau dependentnya si HeartDisease, gausah pake axis karna ga nge drop
      y
      #202431029_Jonathan Juan Setyanto
```

[38]:

```
0      0
1      1
2      0
3      1
4      0
      ..
913    1
914    1
915    1
916    1
917    0
Name: HeartDisease, Length: 918, dtype: int64
```

Penjelasan :

Kode pada cell ini digunakan untuk mendefinisikan variabel target/dependen (y) dengan mengambil kolom 'HeartDisease' dari DataFrame df serta menampilkan isinya sebagai bagian dari alur persiapan pemodelan Decision Tree.

Output tersebut menampilkan Series Pandas dari variabel target HeartDisease sebanyak 918 entri data bertipe int64 yang memuat label klasifikasi biner 0 dan 1.

```
[39]: from sklearn.model_selection import train_test_split #splitting sblm buat model. misah data uji sama data latih dari dataset

x_train, x_test, y_train, y_test = train_test_split(x, y, test_size = 0.25, random_state=0)
#202431029_Jonathan Juan Setyanto
```

Penjelasan :

Kode pada cell ini digunakan untuk membagi matriks fitur (x) dan variabel target (y) menjadi data latih (training set) dan data uji (testing set) dengan proporsi 75% untuk data latih dan 25% untuk data uji (test_size=0.25) menggunakan train_test_split serta menetapkan random_state=0 agar hasil pembagian data bersifat konsisten (reproducible).

Cell ini tidak menghasilkan output teks maupun visual di layar karena proses pembagian data latih (x_train, y_train) dan data uji (x_test, y_test) dilakukan secara internal di dalam memori.

```
[40]: from sklearn.tree import DecisionTreeClassifier

classifier = DecisionTreeClassifier() #inisialisasi model Decison tree
classifier.fit(x_train, y_train) #training model
#202431029_Jonathan Juan Setyanto
```

```
[40]: DecisionTreeClassifier
      ▸ Parameters
```

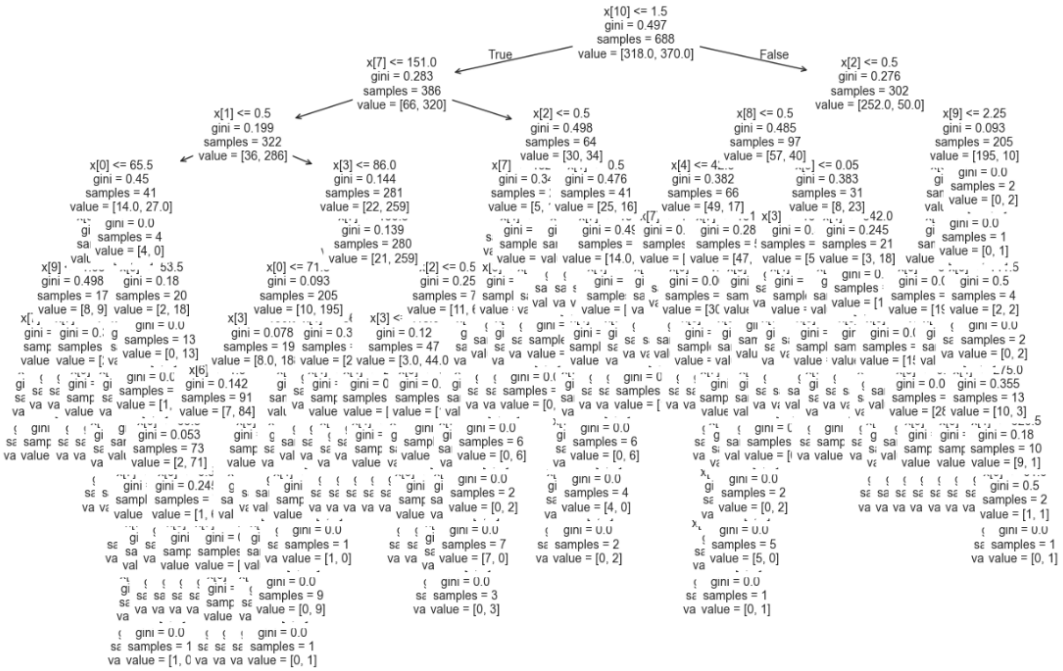
Penjelasan :

Kode pada cell ini digunakan untuk mengimpor DecisionTreeClassifier dari pustaka scikit-learn, menginisialisasi objek model Decision Tree ke dalam variabel classifier, dan melatih (fitting) model tersebut menggunakan pasangan data latih (x_train dan y_train).

Output tersebut menampilkan konfirmasi visual representasi objek DecisionTreeClassifier yang menandakan bahwa proses pelatihan model pohon keputusan telah selesai dilakukan dengan parameter bawaan (default).

[41]:
```
from sklearn import tree #buat pohon keputusannya

plt.subplots(figsize = (15,10)) #ukuran kanvas buat pohonya (seluruh diagram ya, bukan kotak cabangnya)
tree.plot_tree(classifier, fontsize = 10) #buat pohon dari model yg dah dibuat, ukuran fontnya 10
plt.show()
#202431029_Jonathan Juan Setyanto
```



Penjelasan :

Kode pada cell ini digunakan untuk memvisualisasikan alur dan struktur percabangan dari model Decision Tree yang telah dilatih menggunakan fungsi tree.plot_tree() dengan mengatur ukuran kanvas 15x10 dan ukuran font 10.

Output tersebut menampilkan diagram hirarki pohon keputusan yang memperlihatkan kriteria pemisahan (split fitur), nilai Gini impurity, jumlah sampel, dan distribusi nilai kelas pada setiap node.

[42]:
```
from sklearn.tree import DecisionTreeClassifier

classifier = DecisionTreeClassifier(criterion ='entropy', max_depth=5) #inisialisasi model Decison tree memakai entropy
classifier.fit(x_train, y_train) #training model
#202431029_Jonathan Juan Setyanto
```

[42]:
```
▾ DecisionTreeClassifier
▸ Parameters
```

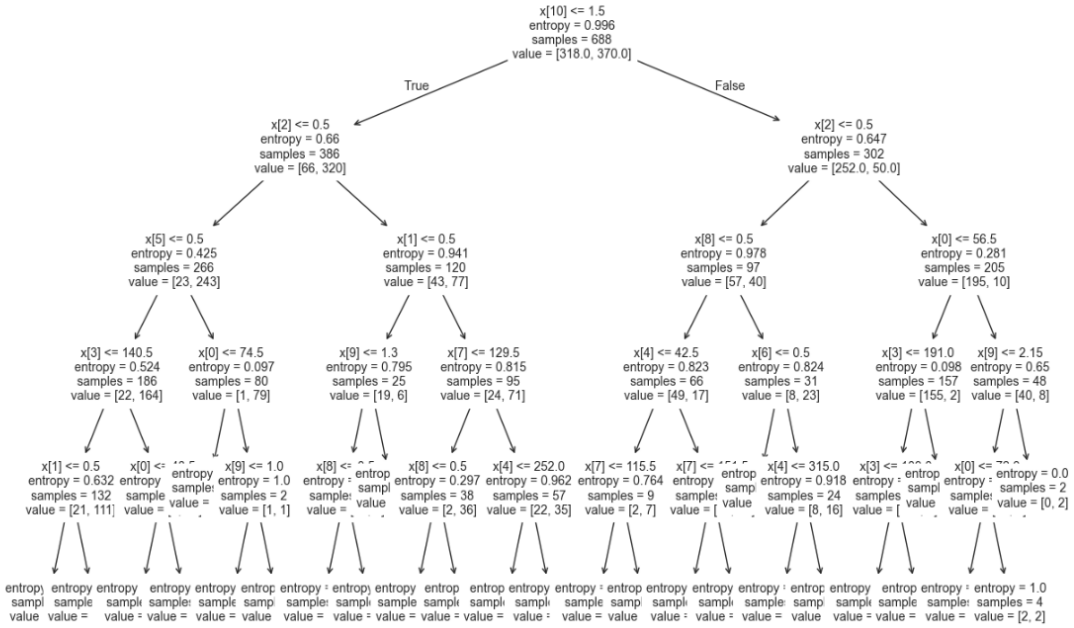
Penjelasan :

Kode pada cell ini digunakan untuk menginisialisasi ulang model Decision Tree dengan menentukan kriteria pemisahan berbasis entropy serta membatasi kedalaman maksimum pohon (max_depth=5), lalu melatihnya (fitting) menggunakan data latih (x_train dan y_train).

Output tersebut menampilkan konfirmasi visual representasi objek DecisionTreeClassifier yang menandakan bahwa proses pelatihan model pohon keputusan dengan kriteria entropy dan pembatasan kedalaman pohon telah selesai dilakukan.

[43]:
```
from sklearn import tree

plt.subplots(figsize = (15,10)) #ukuran kanvas buat pohonya (seluruh diagram ya, bukan kotak cabangnya)
tree.plot_tree(classifier, fontsize = 10) #buat pohon dari model yg dah dibuat, ukuran fontnya 10
plt.show()
#202431029_Jonathan Juan Setyanto
```



Penjelasan :

Kode pada cell ini digunakan untuk memvisualisasikan alur percabangan model Decision Tree yang telah dibatasi kedalamannya (max_depth=5) menggunakan fungsi tree.plot_tree() dengan pengaturan ukuran kanvas 15x10 dan ukuran font 10.

Output tersebut menampilkan diagram pohon keputusan yang lebih terstruktur hingga kedalaman maksimum 5 tingkat, yang memperlihatkan kriteria pemisahan fitur, nilai entropy, jumlah sampel, dan sebaran nilai kelas pada setiap node.

[44]:
```
depth = classifier.get_depth() #buat tahu depth/kedalaman dari tree yg kita buat berapa (berguna kalo turunannya banyak)
depth
#202431029_Jonathan Juan Setyanto
```

[44]:
```
5
```

Penjelasan :

Kode pada cell ini digunakan untuk mengambil dan menampilkan nilai kedalaman (depth) dari struktur pohon keputusan yang telah dilatih menggunakan metode get_depth().

Output tersebut menampilkan angka 5 yang mengonfirmasi bahwa kedalaman maksimum dari model Decision Tree yang terbentuk adalah 5 tingkat sesuai dengan batasan parameter yang telah ditentukan.

[45]:
```
from sklearn.metrics import accuracy_score #ngecek akurasi dari model

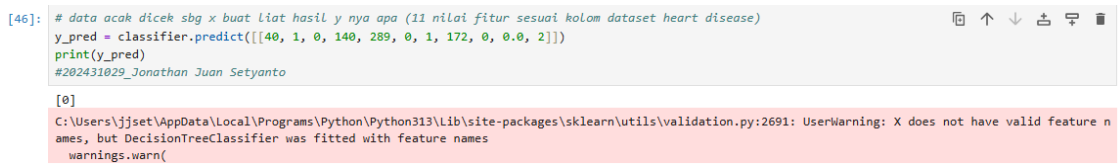
y_pred = classifier.predict(x_test) #prediksi y pakai x nya itu dari x uji/ x_test yg 0.25 itu
akurasi = accuracy_score(y_test, y_pred) #ngecek akurasi bandingin dari y_test (dari dataset) sama y_pred (dari hasil baris diatas)
print(akurasi) #ngeprint, hasilnya pasti 0.xxx bacanya xx%
#202431029_Jonathan Juan Setyanto
```

```
0.8304347826086956
```

Penjelasan :

Kode pada cell ini digunakan untuk melakukan prediksi kelas target pada data uji (x_test) menggunakan model Decision Tree dan menghitung skor akurasinya dengan membandingkan hasil prediksi (y_pred) terhadap label sebenarnya (y_test) menggunakan fungsi accuracy_score.

Output tersebut menampilkan hasil perhitungan akurasi model Decision Tree pada data uji sebesar 0.8304347826086956 atau sekitar 83,04%.



Penjelasan :

Kode pada cell ini digunakan untuk melakukan inferensi atau prediksi terhadap satu sampel data acak dengan 11 nilai fitur menggunakan model Decision Tree yang telah dilatih serta mencetak hasil prediksinya ke layar.

Output tersebut menunjukkan bahwa sampel data acak diprediksi masuk ke dalam kelas [0] (tidak menderita penyakit jantung), disertai peringatan (UserWarning) karena data masukan diberikan dalam bentuk list 2D tanpa menyertakan nama kolom fitur.

BAB IV
PENUTUP

4.1 Kesimpulan

Berdasarkan teori yang telah dipelajari dan praktikum yang dilakukan menggunakan dataset 01_heart_disease.csv, dapat disimpulkan beberapa hal sebagai berikut :

1. Tahap Preprocessing Data
   Proses Exploratory Data Analysis (EDA) dan Data Preprocessing memiliki peran penting dalam mempersiapkan dataset sebelum dilakukan pemodelan. Pengubahan atribut kategorikal seperti Sex, ChestPainType, RestingECG, ExerciseAngina, dan ST_Slope ke dalam bentuk numerik menggunakan LabelEncoder bertujuan agar data dapat diproses oleh algoritma Machine Learning.
2. Penerapan Algoritma Naïve Bayes (GaussianNB)
   Algoritma Naïve Bayes menerapkan perhitungan probabilitas berdasarkan Teorema Bayes dengan asumsi bahwa setiap fitur bersifat independen. Model GaussianNB digunakan untuk melakukan klasifikasi terhadap kondisi penyakit jantung pasien. Evaluasi model dilakukan menggunakan Confusion Matrix dan Classification Report untuk mengetahui hasil serta tingkat ketepatan prediksi.
3. Penerapan Algoritma Decision Tree (DecisionTreeClassifier)
   Algoritma Decision Tree melakukan klasifikasi melalui pembentukan struktur pohon yang terdiri dari beberapa percabangan berdasarkan aturan keputusan tertentu. Penggunaan kriteria Entropy serta pengaturan kedalaman pohon melalui parameter max_depth membantu mengontrol struktur model dan mempermudah pemahaman proses pengambilan keputusan.
4. Kinerja Pemodelan Klasifikasi
   Algoritma Naïve Bayes dan Decision Tree dapat diterapkan untuk menyelesaikan permasalahan klasifikasi pada dataset penyakit jantung. Pembagian dataset menjadi data latih dan data uji (train-test split), serta proses encoding pada atribut kategorikal, merupakan tahapan penting dalam mempersiapkan model agar dapat melakukan prediksi terhadap data baru.

DAFTAR PUSTAKA

[1] Saintikom, J., Sains, J., Informatika, M., & Hidayat, T. (2024). *Exploratory Data Analysis (EDA) untuk Mengetahui Distribusi Data Kualitas Susu Sapi*. *23*, 68–76.

[2] Alghifari, F., & Juardi, D. (2021). *Penerapan Data Mining Pada Penjualan Makanan Dan Minuman Menggunakan Metode Algoritma Naïve Bayes*.

[3] Agung, A., Daniswara, A., & Nuryana, I. K. D. (2023). *Data Preprocessing Pola Pada Penilaian Mahasiswa Program Profesi Guru*. *05*, 97–100.

[4] Rizki, I. N., Puspita, M. L., Prayoga, D., Huda, M. Q., & Selatan, T. (2024). *IMPLEMENTASI EXPLORATORY DATA ANALYSIS UNTUK ANALISIS DAN VISUALISASI DATA PENDERITA STROKE KALIMANTAN SELATAN MENGGUNAKAN*. *12*(1).

[5] Husni, D. T., Ryan, D., Sitompul, H., Sinurat, S. H., Situmorang, A., Ziegel, D. J., Rahmad, J., Indra, E., Studi, P., Informasi, S., Teknologi, F., Ilmu, D., Universitas, K., & Indonesia, P. (2022). *Analisis big data penjualan video games mengunakan eda*. *5*, 43–48. https://doi.org/10.37600/tekinkom.v5i1.517

[6] Cetak, I., & Online, I. (2023). *DECODE : Jurnal Pendidikan Teknologi Informasi*. *3*(2), 161–171.

[7] Machine, I., Dengan, L., Tree, D., & Jakarta, D. (2021). *Jurnal Sosial dan Teknologi (SOSTECH) Implementasi Machine Learning dengan Decision Tree e-ISSN 2774-5155 Algoritma C4 . 5 dalam Penerimaan Karyawan Baru pada p-ISSN 2774-5147 PT . Gitareksa Dinamika Jakarta*. *1*(7), 615–623.

[8] Pebdika, A., Herdiana, R., Solihudin, D., Pintar, P. I., Bayes, N., Penentuan, U., & Bantuan, P. (2023). *KLASIFIKASI MENGGUNAKAN METODE NAIVE BAYES UNTUK MENENTUKAN CALON PENERIMA PIP*. *7*(1), 452–458.

[9] Martantoh, E., Yanih, N., Informatika, T., Panca, U., & Bekasi, S. (2022). *Implementasi Metode Naïve Bayes Untuk Klasifikasi Karakteristik Kepribadiaan Siswa Di Sekolah MTS Darussa ' adah Menggunakan PHP MySQL*. *3*(2), 166–175.

[10] Biyantoro, A. S., & Prasetiyo, B. (2024). *Application of Decision Tree for Health Status Classification , Compared to KNN and Naive Bayes Penerapan Decision Tree untuk Klasifikasi Status Kesehatan dengan perbandingan KNN dan Naive Bayes*. *4*(1), 47–55.

[11] Pembelajaran, P., Solehuddin, M., Syafei, W. A., & Gernowo, R. (2022). *Metode Decision Tree untuk Meningkatkan Kualitas Rencana*. *6*(3), 510–519.